

Copyright © Todos los Derechos Reservados - Cibertec Perú SAC

Tipo : Guía de Laboratorio

Capítulo : Machine Learning en Python

Duración: 60 minutos

I. OBJETIVO

Demostrar competencias básicas en machine learning usando el caso Titanic.

II. REQUISITOS

Los siguientes elementos de software son necesarios para la realización del laboratorio:

- Instalar Anaconda en Windows
- Navegador web

III. EJECUCIÓN DEL LABORATORIO

Ejercicio: Caso Titanic.

- Crear un entorno virtual
- conda create --name labtitanic python=3.5
- activatelabtitanic
 - 2.1.1 pipinstall
 - a. jupyter
 - b. matplotlib
 - c. scikit-learn
 - d. pandas
- Activar jupyter en la línea de comandos con jupyter notebook
- Abrir Titanic.ipynb en el browser
- Ejecutar el código y consultar




1. Introducción




2. Exploración clase de pasajeros




3. Exploración sexo



4. Exploración punto de embarque



5. Limpieza datos de categoría



```
In [29]: # encode "Sex"
         from sklearn.preprocessing import LabelEncoder
         labelEncoder_X = LabelEncoder()
         X.Sex=labelEncoder_X.fit_transform(X.Sex)
In [11]: X.head()
Out[11]:
           Polass
                                               Name Sex Age Embarked
                                   Braund, Mr. Owen Harris 1 22.0
         0 3
         1

    Cumings, Mrs. John Bradley (Florence Briggs Th...

                                                      0 38.0
             3
                                    Heikkinen, Miss. Laina 0 26.0
         3 1
                  Futrelle, Mrs. Jacques Heath (Lily May Peel) 0 35.0
                                                                    S
                        Allen, Mr. William Henry 1 35.0 S
```

```
In [30]: # number of null values in embarked:
        print ('Number of null values in Embarked:', sum(X.Embarked.isnull()))
         Number of null values in Embarked: 2
In [31]: row_index = X.Embarked.isnull()
         X.loc[row_index,'Embarked']='S
In [32]: # encode "Embarked"
         from sklearn.preprocessing import LabelEncoder
         labelEncoder_X = LabelEncoder()
         X.Embarked=labelEncoder_X.fit_transform(X.Embarked)
In [33]: X.head()
Out[33]:
            Pclass
                                               Name Sex Age Embarked
         0 3
                       Braund, Mr. Owen Harris 1 22.0 2
               1 Cumings, Mrs. John Bradley (Florence Briggs Th...
                                                       0 38.0
                                                                    0
         2 3
                                  Heikkinen, Miss. Laina 0 28.0
                                                                    2
         3
                     Futrelle, Mrs. Jacques Heath (Lily May Peel)
                                                      0 35.0
                                                                    2
         4 3 Allen, Mr. William Henry 1 35.0 2
```

```
In [34]: #Drop Name
          X=X.drop(['Name'], axis=1)
         X=X.drop(['Age'], axis=1)
         X.head()
Out[34]:
             Polass Sex Embarked
                               2
          0
          1
                     0
                               0
                 1
                     0
                               2
          2
                 3
          3
                 1
                     0
                               2
                               2
                3 1
```

6. Predicciones

IV. EVALUACIÓN

- 1. ¿Cuáles son las fases esenciales del análisis de este caso?
 - a. Respuesta: exploración, limpieza y modelos.
- 2. ¿Qué permite la exploración en este caso?
 - a. **Respuesta:** entre otras cosas familiarizarse con el dataset, identificar el estado de los datos y reconocer las variables clave para el modelo.
- 3. ¿Por qué es importante la limpieza de datos en este caso?
 - Respuesta: en este caso particular se ajusta la data para que funcione el modelo. Concretamente, ya que usamos modelos de clasificación se debe procurar transformar datos de texto a datos numéricos